SentimentAI Banking | Versión 2

Actividad 5 · Gestión de proyectos de inteligencia artificial

Elizabeth Rivera Noguez | 18 de octubre de 2026

Preparación, entrenamiento y trazabilidad de un clasificador de intenciones bancarias

Resultado principal. La regresión logística fue seleccionada por F1 macro de validación cruzada (0.8824). En el test independiente limpio obtuvo 90.06% de exactitud y F1 macro de 0.9008. Naive Bayes obtuvo 85.68% y 0.8558, respectivamente.

Alcance. Esta etapa amplía el proyecto anterior: pasa de sentimiento en comentarios sintéticos en español a intención en consultas públicas en inglés. Las métricas de ambas actividades no son comparables directamente. El objetivo es identificar el motivo de consulta para apoyar su canalización; no resolver reclamaciones ni tomar decisiones jurídicas o crediticias.

1. Fuente y diccionario

BANKING77, publicado por PolyAI: 10,003 ejemplos de entrenamiento, 3,080 de prueba y 77 intenciones. Se fija la revisión 57ec275d8078af65b7731c2a98be812d844a6d6b y se conserva la licencia CC BY 4.0. Los datos no son de BBVA ni representan por sí mismos a clientes mexicanos.

Campo	Descripción
text	Consulta original en inglés; después, texto normalizado.
category	Una de las 77 intenciones; variable objetivo.
id / text_original	Campos añadidos: índice original con partición y texto sin modificar.

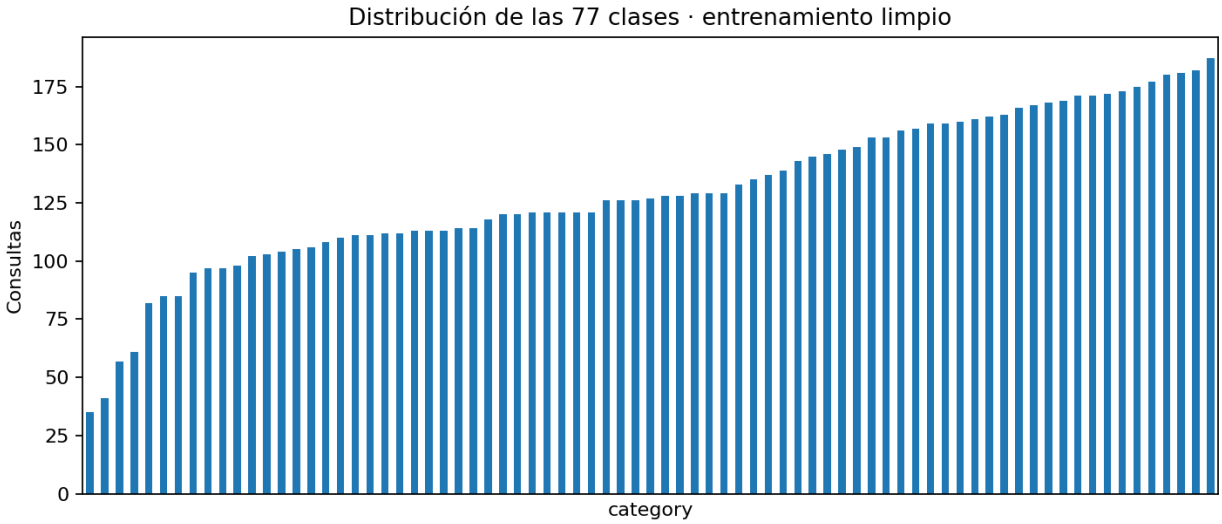
2. Limpieza y versionamiento

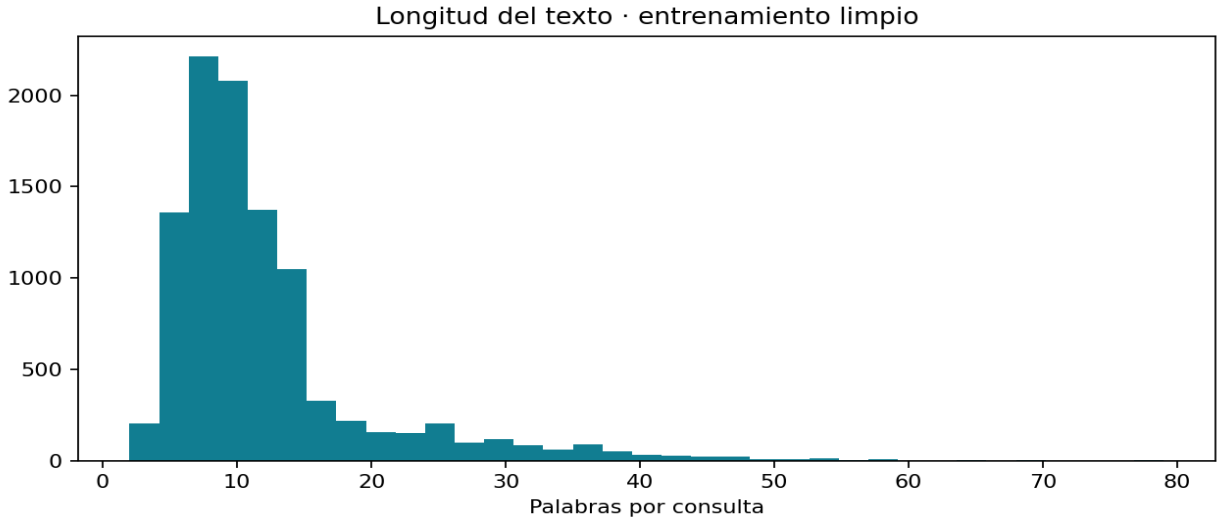
Se valida el esquema y el SHA256 de cada CSV. Se aplican Unicode NFKC, espacios uniformes y minúsculas, preservando puntuación y negaciones. No se detectaron textos vacíos ni etiquetas conflictivas. Se excluyeron 7 textos de entrenamiento coincidentes con test y 5 duplicados dentro de las particiones. Quedan 9,992 ejemplos de train y 3,079 de test. Las exclusiones conservan ID y motivo.

datos_ini conserva los originales; datos_limp contiene la versión procesada, calidad.json y exclusiones.csv. El manifiesto registra fuente, revisión y hashes. CHANGELOG documenta las transformaciones. El hash del código y, cuando existe, el commit de Git se registran en MLflow. Se detectan coincidencias exactas normalizadas, no toda posible paráfrasis.

Diseño del experimento

3. Patrones y calidad





Las clases de entrenamiento contienen entre 35 y 187 ejemplos; la longitud mediana es 10 palabras y la máxima 79. Las clases están relativamente equilibradas, pero algunas consultas extensas pueden expresar varios detalles. No se recortan textos largos sin una justificación de negocio.

4. Modelos e hiperparámetros

Ambos algoritmos usan un Pipeline con TF-IDF (min_df=2, sublinear_tf=True, máximo 30,000 términos). La normalización L2 está incluida; no se aplica un escalado numérico adicional. El vocabulario y los pesos se aprenden dentro de cada fold para evitar fuga de información.

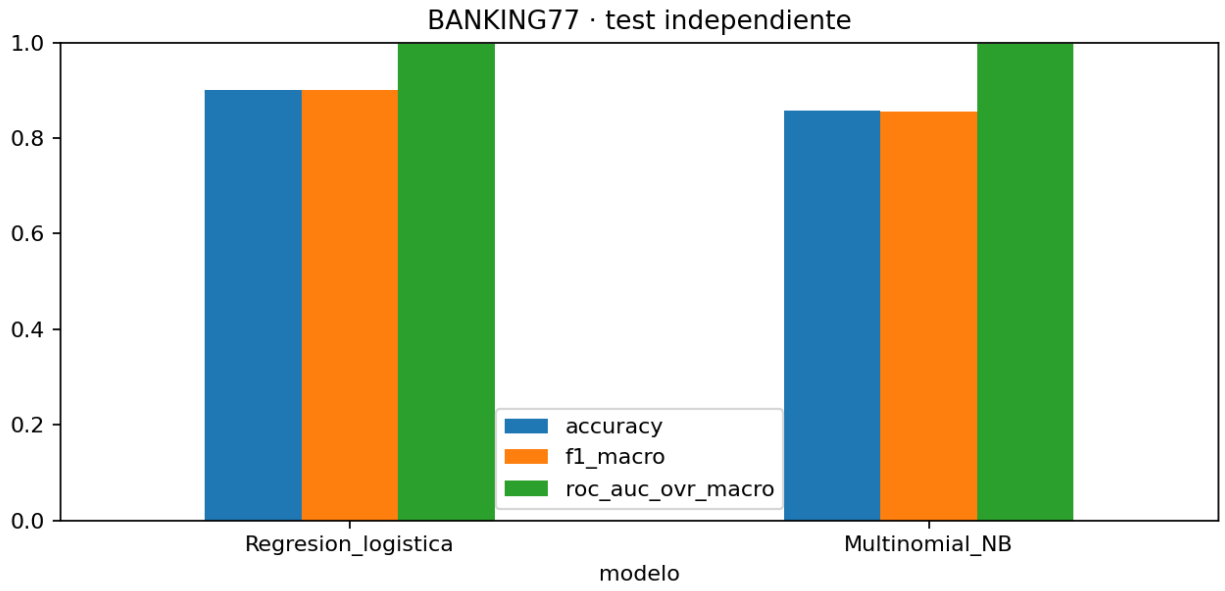
Regresión logística: C de 0.5, 2 y 8; solver lbfgs y máximo 1,000 iteraciones. C contrasta distinta regularización. Naive Bayes multinomial: alpha de 0.1, 0.5 y 1; el suavizado reduce el efecto de términos raros. Ambos prueban unigramas y unigramas con bigramas: seis candidatos por algoritmo.

Evaluación y comparación

5. Protocolo y resultados

GridSearchCV con cinco folds estratificados comunes, shuffle y semilla 42: 60 ajustes CV más dos reajustes finales. El criterio de selección es F1 macro de CV, que pondera por igual las categorías. El test se reserva para la evaluación final y no se usa para escoger hiperparámetros.

Métrica	Logística	Naive Bayes
F1 macro CV	0.8824	0.8391
Desviación F1 CV	0.0057	0.0122
Accuracy test	0.9006	0.8568
Precisión macro	0.9049	0.8654
Recall macro	0.9006	0.8568
F1 macro test	0.9008	0.8558
ROC-AUC OVR macro	0.9980	0.9973



ROC-AUC OVR macro mide separación uno-contra-resto, no acierto top-1. Por ello un AUC cercano a uno puede coexistir con confusiones entre intenciones próximas. Se informa junto con F1 y la matriz completa; los scores no se consideran probabilidades calibradas.

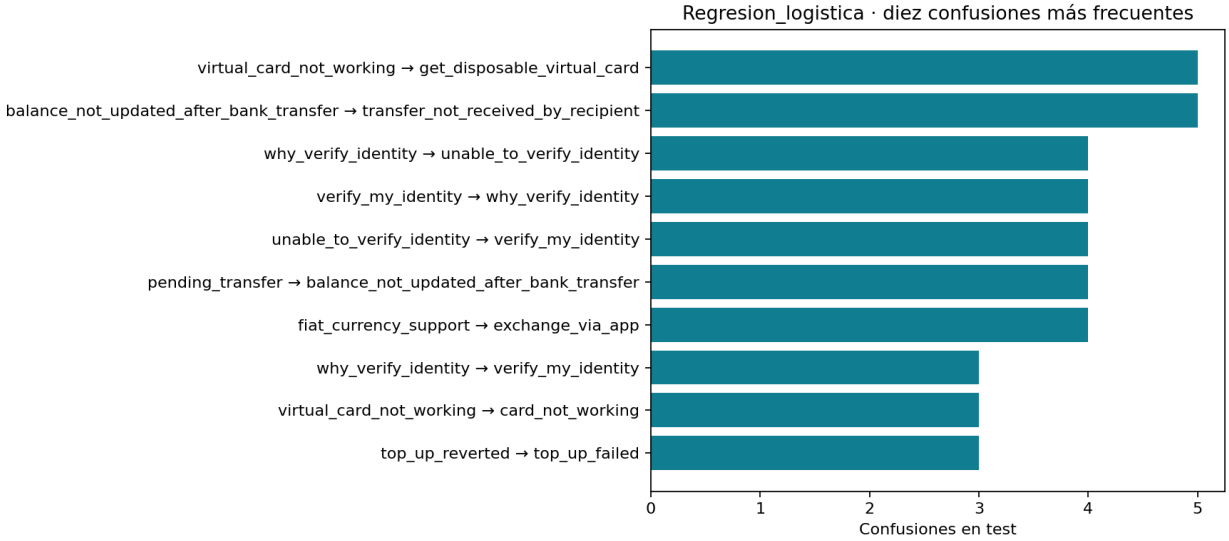
Configuraciones seleccionadas por CV: logística con C=8 y unigramas; Naive Bayes con alpha=0.1 y unigramas. Los bigramas no mejoraron el criterio de selección en la cuadrícula evaluada.

6. Comparación estadística

La diferencia de exactitud observada es de 4.38 puntos porcentuales a favor de logística. Bootstrap pareado estratificado por clase (1,000 réplicas, semilla 42): IC95% de 3.31 a 5.42 puntos. McNemar exacto compara 201 aciertos exclusivos de logística con 66 exclusivos de NB: p=4.95e-17. Hay evidencia de diferencia en este test fijo, sin demostrar utilidad en producción. El bootstrap supone consultas intercambiables dentro de clase. La desviación de los folds no se interpreta como un intervalo independiente.

Errores y trazabilidad

7. Errores observados



Regresion_logistica. Consulta: “my transfer is pending.”. Referencia: balance_not_updated_after_bank_transfer; predicción: pending_transfer; score máximo 0.997.

Multinomial_NB. Consulta: “how many transactions can i make with a disposable card”. Referencia: get_disposable_virtual_card; predicción: disposable_card_limits; score máximo 0.964.

Estos desaciertos muestran que el score alto no garantiza una etiqueta correcta. Conviene revisar categorías próximas y ambigüedades, sin atribuir al modelo una causa interna que no se haya probado. Las predicciones completas y matrices de 77 clases están disponibles como CSV.

8. Registro y reproducibilidad con MLflow

Se registran dos ejecuciones padre, seis hijas por algoritmo y una comparación final. Cada candidato conserva parámetros, F1 y accuracy CV, dispersión y métricas por fold. Los runs padre incluyen hashes de datos y código, semilla, métricas finales, CSV de evaluación, modelo y metadatos. Se comprobó la recuperación de ambos modelos desde MLflow y la igualdad de sus predicciones en diez consultas.

Se incluye el seguimiento real en evidencias/seguimiento_mlflow.zip y un script para restaurar rutas al cambiar de equipo. El notebook reproduce el proceso y abre el panel de MLflow en Colab. La ejecución de Colab utiliza Python 3.13.16, scikit-learn 1.8.0 y MLflow 2.22.2; requirements.txt fija las dependencias.

Evidencia de Colab. Se verificaron 15 runs finalizados y las salidas del notebook. Se anexan seis capturas reales del panel. Los tiempos de búsqueda fueron 120.98 s para logística y 14.57 s para NB; dependen del entorno. Los modelos se conservan como artefactos recuperables. El entrenamiento se identifica mediante SHA256; la etiqueta sin_commit_local indica que Colab no se ejecutó dentro de un clon Git.

Decisión y deuda técnica

9. Acciones MLOps

Límite o deuda	Acción y evidencia de cierre
Idioma y representatividad	Validación independiente en español, etiquetada y revisada; métricas y errores por categoría.
Consultas desconocidas	Diseñar abstención y atención humana; evaluar fuera de dominio y curva cobertura/error en validación separada.
Scores sin calibrar	Si se usarán umbrales, calibrar sobre desarrollo separado y medir calibración y log-loss.
Cambios del servicio	Monitorizar categorías, vocabulario y rendimiento con etiquetas recientes; definir revisiones y alertas.
Reproducción manual	Automatizar esquema, hashes, no solapamiento y prueba de carga; detener publicación ante fallos.
Artefactos locales	Conservar exportación y recrear rutas o usar almacenamiento compartido controlado. Verificar reconstrucción en un entorno nuevo.

10. Conclusión

La regresión logística es la alternativa seleccionada para este experimento por su mayor F1 macro en validación cruzada. La evaluación independiente y la comparación pareada respaldan esa decisión en BANKING77. Naive Bayes ofrece una referencia simple y rápida, con menor desempeño en esta ejecución. El análisis demuestra un flujo trazable de preparación, ajuste y registro, sin convertir el resultado académico en una validación operativa.

El siguiente paso es revisar los errores con criterio de servicio y validar datos actuales en español, consultas desconocidas y políticas de intervención humana. Se conservan la actividad 4 y sus resultados como antecedente; esta versión documenta expresamente el cambio de tarea, idioma y dataset.

Referencias y transparencia

Casanueva, I., Temcinas, T., Gerz, D., Henderson, M. y Vuli■, I. (2020). Efficient Intent Detection with Dual Sentence Encoders. NLP4ConvAI. https://aclanthology.org/2020.nlp4convai-1.5/

PolyAI. BANKING77. https://github.com/PolyAI-LDN/task-specific-datasets (revisión fijada en el manifiesto; licencia incluida).

scikit-learn. GridSearchCV. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html

MLflow. Tracking, versión 2.22.2. https://mlflow.org/docs/2.22.2/tracking.html

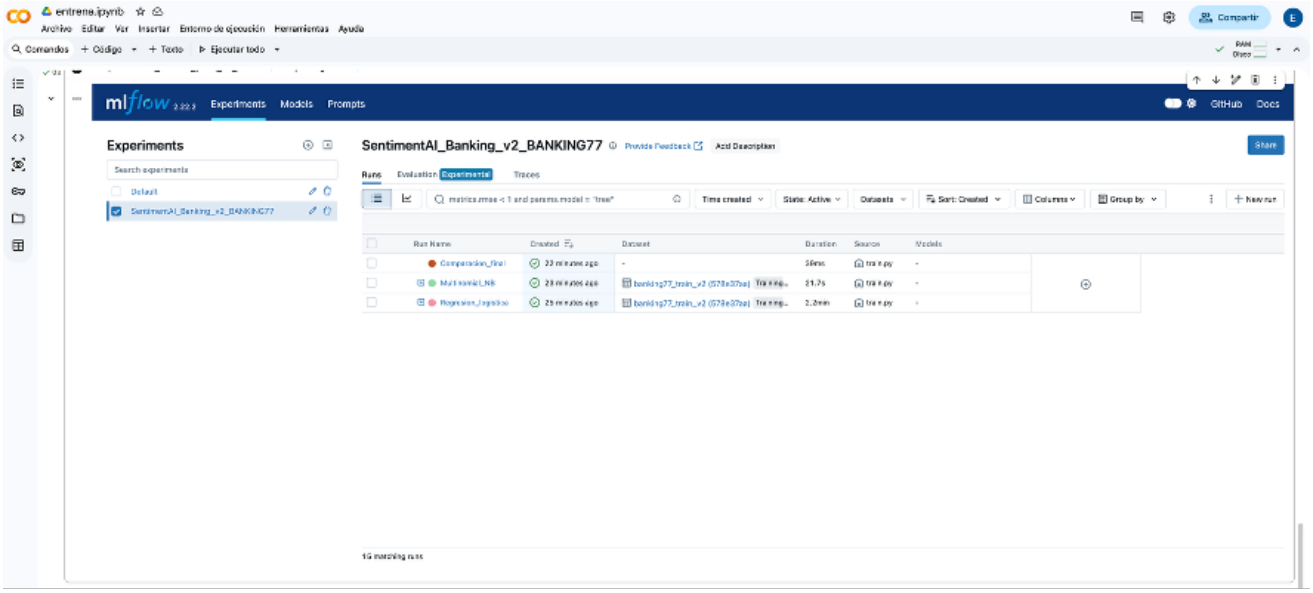
Se utilizó asistencia de IA para código, documentación y revisión de consistencia. Las métricas se calcularon ejecutando los modelos. Se conservan las salidas y las capturas de la ejecución de Colab para contrastar el análisis.

Anexo | Evidencias de MLflow

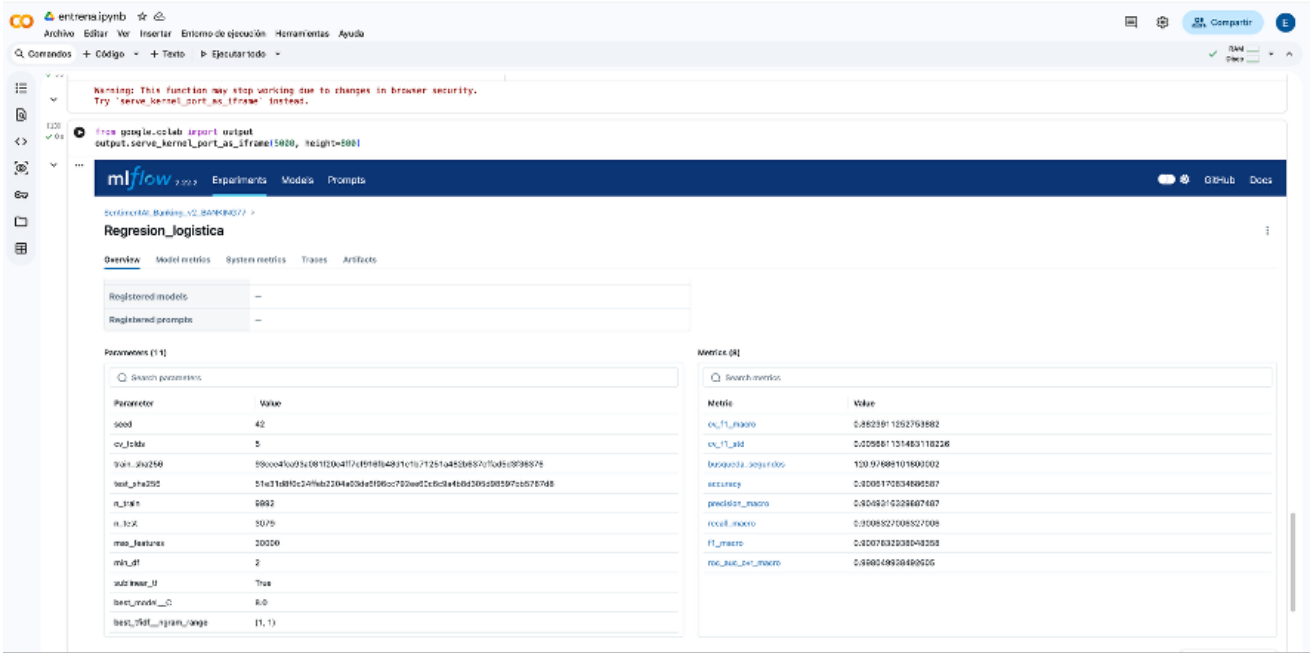
Capturas reales de Colab, 18 de octubre de 2026. Se conservan los PNG originales en evidencias/. Los identificadores vinculan estas vistas con el seguimiento exportado.

Logística: b53faf52f78b411db7dae03196a0eb8a
Naive Bayes: a0e5a0c38b5d4c34b439081b92efa3fe

1. Experimento y ejecuciones principales.

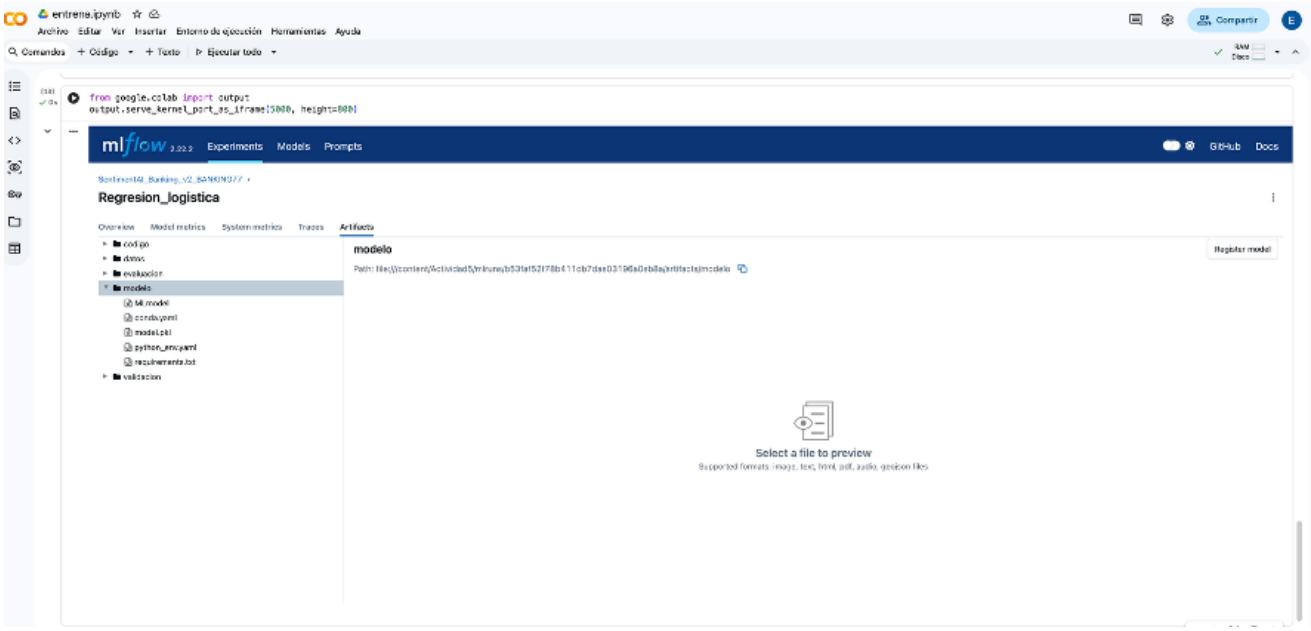


2. Regresión logística: parámetros y métricas.

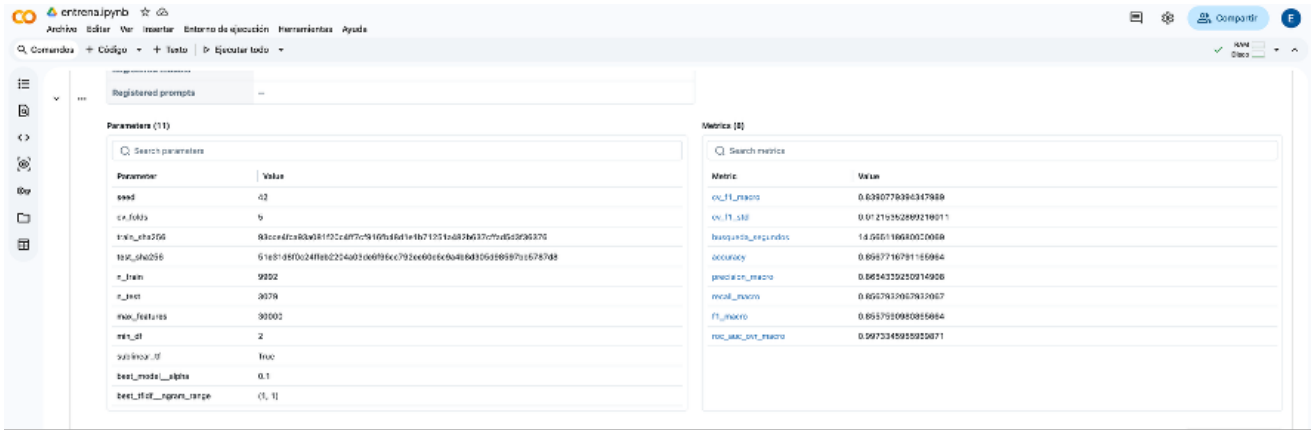


Anexo | Evidencias de MLflow

3. Regresión logística: modelo guardado.

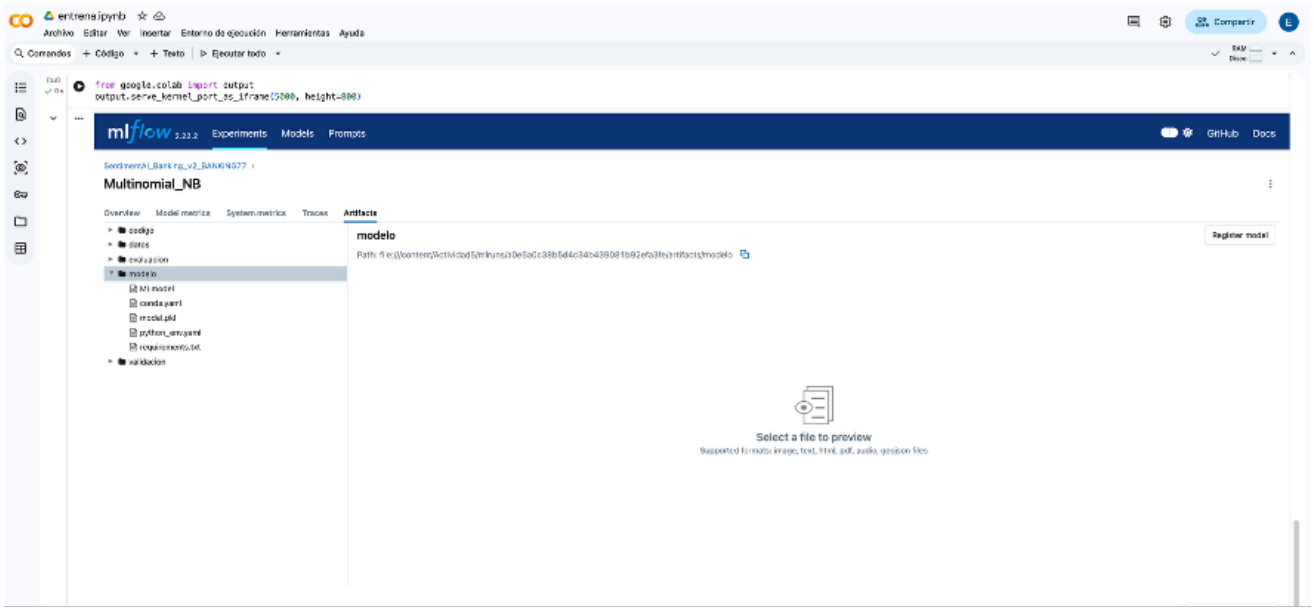


4. Naive Bayes: parámetros y métricas.



Anexo | Evidencias de MLflow

5. Naive Bayes: modelo guardado.



6. Comparación: NB a la izquierda; logística a la derecha. Los parámetros alpha=0.1 y C=8 identifican las columnas cuyo encabezado no está en el recorte.

